

## דף נוסחאות למבחן

### הגדרות בסיסיות בהסתברות

תוחלת (mean/expectation) של משתנה אקראי:

$$E[X] = \sum_i x_i p(x_i) \equiv \mu$$

שונות (variance) של משתנה אקראי:

$$Var(X) = E[(X - \mu)^2] = E[X^2] - \mu^2 \equiv \sigma^2$$

שונות משותפת (covariance) של שני משתנים אקראיים  $X$  ו  $Y$ :

$$Cov(X, Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - \mu_X \mu_Y$$

ההסתברות המותנית של  $Y$  בהינתן  $X$  מוגדרת ע"י:

$$p(y|x) = \frac{p(x, y)}{p(x)}$$

ההסתברות המותנית של  $Y$  בהינתן  $X$  עבור התניה במשתנה שלישי  $Z$ :

$$p(x, y|z) = p(y|x, z)p(x|z)$$

כלל Bayes:

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)} = \frac{p(x|y)p(y)}{\sum_i p(x|y_i)p(y_i)}$$

צפיפות ההתפלגות של וקטור אקראי גאوسی:

$$f(x_1, x_2, \dots, x_k) = \frac{1}{\sqrt{(2\pi)^k |\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{X} - \boldsymbol{\mu})\right)$$

### חוקי גזירה וקטורית

$$\begin{aligned} \frac{\partial}{\partial \underline{x}} (\underline{a}^T \underline{x}) &= \frac{\partial}{\partial \underline{x}} (\underline{x}^T \underline{a}) = \underline{a} \\ \frac{\partial}{\partial \underline{x}} (\underline{x}^T \underline{A} \underline{x}) &= (\underline{A}^T + \underline{A}) \underline{x} \\ \frac{\partial z}{\partial \underline{x}} &= \frac{\partial y}{\partial \underline{x}} \frac{\partial z}{\partial y} \\ \frac{\partial z}{\partial \underline{x}} &\neq \frac{\partial z}{\partial y} \frac{\partial y}{\partial \underline{x}} \text{ בדרך כלל} \\ \frac{\partial}{\partial \underline{x}} \underline{A}^T \underline{x} &= \frac{\partial}{\partial \underline{x}} \underline{x}^T \underline{A} = \underline{A} \end{aligned}$$

$$\begin{aligned} \frac{\partial}{\partial \underline{x}} (\underline{A} \underline{x} + \underline{b})^T (\underline{A} \underline{x} + \underline{b}) &= 2 \underline{A}^T (\underline{A} \underline{x} + \underline{b}) \\ \frac{\partial}{\partial \underline{x}} (\underline{A} \underline{x} + \underline{b})^T \underline{C} (\underline{A} \underline{x} + \underline{b}) &= \underline{A}^T (\underline{C} + \underline{C}^T) (\underline{A} \underline{x} + \underline{b}) \\ \frac{\partial}{\partial \underline{x}} (\underline{A} \underline{x} + \underline{b})^T (\underline{D} \underline{x} + \underline{e}) &= \underline{A}^T (\underline{D} \underline{x} + \underline{e}) + \underline{D}^T (\underline{A} \underline{x} + \underline{b}) \\ \frac{\partial}{\partial \underline{x}} (\underline{A} \underline{x} + \underline{b})^T \underline{C} (\underline{D} \underline{x} + \underline{e}) &= \underline{A}^T \underline{C} (\underline{D} \underline{x} + \underline{e}) + \underline{D}^T \underline{C}^T (\underline{A} \underline{x} + \underline{b}) \end{aligned}$$

## שערוך פרמטרים

משערוך הסבירות המירבית (Maximum Likelihood Estimator) של  $\theta$ :

$$\hat{\theta}_{MLE} \triangleq \arg \max_{\theta \in \mathbb{R}^p} p(D | \theta) = \arg \max_{\theta \in \mathbb{R}^p} \{\log p(D | \theta)\}$$

משערוך MAP:

$$\hat{\theta}_{MAP} \triangleq \arg \max_{\theta \in \mathbb{R}^p} p(\theta | D) = \arg \max_{\theta \in \mathbb{R}^p} \{\log p(\theta | D)\}$$

## סיווג בייסיאני

$$f(x) = \arg \max_{i=1, \dots, N} p(y = C_i | x)$$

## פונקציית הרגרסיה הלינארית

מנסים למצוא קירוב טוב ככל האפשר ל- $f_0(x) = Y - \varepsilon$  ע"י

$$\hat{f}(x, w) = w^T \phi(x) = \sum_{m=1}^M w_m \phi_m(x)$$

כאשר  $\{\phi_m(x)\}_{m=1}^M$  הוא אוסף פונקציות בסיס שנבחרות מראש, ו- $w = (w_1, \dots, w_M)^T$  הוא ווקטור הפרמטרים הנלמדים,  $w \in \mathbb{R}^M$ .

בחירת הפרמטרים תתבצע לפי קריטריון השגיאה האמפירית הריבועית ביחס לסדרת הלימוד:

$$w^* = \arg \min_{w \in \mathbb{R}^M} \left\{ \sum_{k=1}^n (y_k - \hat{f}(x_k, w))^2 \right\} = \arg \min_{w \in \mathbb{R}^M} \left\{ \sum_{k=1}^n (y_k - w^T \phi(x_k))^2 \right\} \quad (*)$$

## קריטריונים לגידול עץ החלטה:

$$Q(S) = 1 - \max_{j \in \{1, \dots, C\}} \hat{p}_j \quad 1. \text{ שגיאת הסיווג:}$$

$$Q(S) = \sum_j \hat{p}_j (1 - \hat{p}_j) \quad 2. \text{ אינדקס Gini:}$$

$$Q(S) = H(S) = \sum_j \hat{p}_j \log_2 \frac{1}{\hat{p}_j} = - \sum_j \hat{p}_j \log_2 (\hat{p}_j) \quad 3. \text{ אנטרופיה:}$$

**אופטימיזציה ללא אילוצים**

נתונה פונקציית מחיר,  $f(x): \mathbb{R}^n \rightarrow \mathbb{R}$ , התלויה בווקטור פרמטרים  $x = (x_1, x_2, \dots, x_n)^T$ .

נרצה למצוא  $x^*$  המביא למינימום את פונקציית המחיר,  $f(x^*) \leq f(x) \quad \forall x \in X$ , כאשר אין אילוצים על  $x$ .

**תנאים לאופטימליות**

היעד:  $w^* = \arg \min_{w \in \mathbb{R}^n} f(w)$ .

בהנחה ש- $f$  גזירה, תנאי הכרחי לנקודת מינימום מקומית הוא:  $\nabla f(w^*) = 0$

אם בנוסף  $f$  גזירה פעמיים, תנאי מספיק לנקודת מינימום מקומית מבודדת הוא:

$$H(w^*) > 0 \text{ and } \nabla f(w^*) = 0$$

משמעות אי-השוויון היא שההסיאן הוא מטריצה חיובית מוגדרת (שכל הערכים העצמיים שלה חיוביים).

**אלגוריתם הגרדיאנט לאופטימיזציה נטולת אילוצים:**

**מטרה:** במקרים רבים לא ניתן לחשב את  $w^*$  באופן ישיר ולכן משתמשים בטכניקות פתרון איטרטיביות.  
כלומר, מתחילים מניחוש  $w(0) = w_0$  ומייצרים סדרה  $w(t+1) = w(t) + \Delta w(t)$ , כך שיתקיים  $f(w(t+1)) \leq f(w(t))$ , "בתקווה" שהסדרה תתכנס למינימום.

**קלט:** רמת דיוק  $thresh$  ונקודת מוצא  $w_0$ .

**האלגוריתם:**

1. אתחל את נקודת המוצא של האלגוריתם  $w_0$ .

2. עדכן את הפרמטרים בכיוון הנגדי לגרדיאנט בנקודה:

$$w_{t+1} = w_t + \Delta w_t$$

$$\Delta w_t = -\eta g(w_t)$$

3. בדיקת התכנסות:


$$- \text{אם } |w_{t+1} - w_t| \leq thresh$$

סיים אלג' ותן נקודה  $w_{t+1}$  כפתרון.

- אחרת – חזור לשלב 2.

### גאומטריה של מישור

- היטל של ווקטור  $x$  בכיוון ווקטור  $w$ :  $\frac{w^T x}{\|w\|}$
- משוואה של מישור ב  $\mathbb{R}^d$ :  $w^T x + b = 0$ , עבור  $w \in \mathbb{R}^d, b \in \mathbb{R}$  קבועים המגדירים את המישור. מהמשוואה ברור ש  $cw, cb$  עבור קבוע כלשהו  $c$  מגדירים את אותו מישור כמו  $w, b$ .
- מרחק אוקלידי של נקודה  $x_0$  מהמישור המוגדר ע"י  $w, b$ :  $d = \frac{w^T x_0 + b}{\|w\|}$ . בהצבת  $x = 0$  מתקבל שהמרחק של הראשית מהמישור הוא  $d_0 = \frac{b}{\|w\|}$ . הסימן של  $d$  קובע האם הנקודה בצד של המישור לכיוון המקביל ל  $w$ , או לכיוון האנטי-מקביל ל  $w$ :



### SVM

ניסוח הבעיה הפרימאלית: (P)

$$\begin{aligned} \min_{w,b} \quad & \frac{1}{2} \|w\|^2 \\ \text{s.t.} \quad & y_k (w^T x_k + b) \geq 1, \quad k = 1, 2, \dots, n \end{aligned}$$

ניסוח הבעיה הדואלית: (D)

$$\begin{aligned} \max_{\alpha} \quad & \sum_{k=1}^n \alpha_k - \frac{1}{2} \sum_{k,l=1}^n \alpha_k \alpha_l y_k y_l \langle x_k, x_l \rangle \\ \text{s.t.} \quad & \alpha_k \geq 0, \quad k = 1, 2, \dots, n \\ & \sum_{k=1}^n \alpha_k y_k = 0 \end{aligned}$$

## חומי PAC:

### עבור מחלקת היפותזות סופית:

- חסם למידה אגנוסטית  $(f^* \notin F)$ :

$$(1) \quad \forall \varepsilon > 0: \mathbb{P}\{L(\hat{f}_n) - L^* > \varepsilon\} < 2|F|e^{-\varepsilon^2 n/2}$$

- חסם על שגיאת השערוך עבור חזאי בר-מימוש  $(f^* \in F)$ :

$$(2) \quad \forall \varepsilon > 0: \mathbb{P}\{L(\hat{f}_n) > \varepsilon\} < |F|e^{-\varepsilon n}$$

### עבור מחלקת היפותזות אינסופית:

- עבור מקדם ניתוח ידוע:

$$\forall \varepsilon > 0: \mathbb{P}\{L(\hat{f}_n) - L^* > \varepsilon\} < 4S_F(2n)e^{-\varepsilon^2 n/32}$$

- עבור  $VC \dim = V$ :

$$\forall \varepsilon > 0: \mathbb{P}\{L(\hat{f}_n) - L^* > \varepsilon\} < 4(2n+1)^V e^{-\varepsilon^2 n/32}$$

## מימד VC

- ממד VC של מחלקת היפותזות F נתון ע"י:

$$\begin{aligned} VC(F) &\triangleq \max\{n \geq 1 : S_F(n) = 2^n\} \\ &\equiv \max\{n \geq 1 : \max_{\{x_1 \dots x_n\} \subset X} S_F\{x_1 \dots x_n\} = 2^n\} \end{aligned}$$

- מקדם הניתוח מוגדר ע"י המקסימום של  $S_F\{x_1, \dots, x_n\}$  על כל קבוצת הנקודות האפשריות, כלומר:

$$S_F(n) \triangleq \max_{\{x_1 \dots x_n\} \subset X} S_F\{x_1, \dots, x_n\}$$

- הלמה של Sauer:

$$S_F(n) \leq \sum_{i=0}^V \binom{n}{i} \leq (n+1)^V$$

- $S_F\{x_1, \dots, x_n\} \triangleq |\{(f(x_1), \dots, f(x_n)) : f \in F\}|$  מייצג את כמות הדיכטומיות השונות שמחלקה F

משרה על הקבוצה  $\{x_1, \dots, x_n\}$ .

**נורמות:**

עבור וקטור  $x \in \mathbb{R}^m$

$\ x\ _1 = \sum_{i=1}^n  x_i $	נורמת $L_1$ :
$\ x\ _2 = \sqrt{\sum_{i=1}^n x_i^2}$	נורמת $L_2$ :
$\ x\ _\infty = \max_i x_i$	נורמת $L_\infty$ :
$\ x\ _p = \left( \sum_{i=1}^n  x_i ^p \right)^{1/p}$	נורמת $L_p$ :